

Utilizando Redes Neurais Artificiais do tipo Perceptron Multicamadas para resolver *peak finding* em Sinais de Eletrocardiograma.

Brochado, I. D.

Escola de Ciências Exatas e da Computação. Pontifícia Universidade Católica de Goiás

PUC-GOÍÁS

Goiânia, Brasil

igorduartetkd@gmail.com

Resumo—Para determinar a frequência cardíaca a partir de um eletrocardiograma (ECG) de forma automática, um problema que se encontra é a identificação do pico da onda QRS, chamado de *peak finding*. Várias técnicas já são utilizadas para realizar *peak finding*, como *threshold detection* e *OS-CFAR*, porém, elas não levam em consideração o tipo de problema a ser resolvido. Estudos apontam uma eficiência superior utilizando combinações de técnicas de pré-processamento com RNAs, que inclusive, mostraram resultados próximos aos ótimos. Este artigo especifica um agente inteligente único que utiliza redes neurais artificiais (RNA) do tipo Perceptron Multicamadas (MLP) e *backpropagation* como processo de aprendizagem para realizar o *peak finding* em sinais de ECG e identificar automaticamente a frequência cardíaca.

Palavras-chave—Redes neurais artificiais (RNA), perceptron multicamadas (MLP), eletrocardiograma (ECG), *peak finding*

I. Introdução

O coração possui um funcionamento eletromecânico em que as células produzem uma corrente elétrica que pode ser medida com eletrodos sobre a pele. Essa descarga elétrica varia de acordo com a fase que compõe o ciclo cardíaco: Diástole, Sístole auricular e Sístole ventricular [1].

O eletrocardiograma (ECG) é a representação gráfica dos sinais obtidos pelos eletrodos ao longo do tempo. Analisando estes sinais é possível identificar os batimentos cardíacos, que se manifestam em padrões repetidos ao longo do tempo.

Os dados obtidos do ECG variam para cada pessoa de acordo com as condições física e emocional do indivíduo. Um dos desafios para a interpretação automática do ECG é identificar automaticamente a frequência cardíaca. Esta é uma variável de base para diagnóstico e prognóstico da condição do indivíduo. Para isso, um problema que se apresenta é a detecção automática de picos, em inglês, *peak finding*.

Existem várias técnicas para resolver o *peak finding* como a *threshold detection* [3] e a *OS-CFAR* [4] que classifica as amostras em ordem crescente. Porém, estas técnicas não

utilizam informações sobre a forma de pico esperada, por exemplo a onda QRS.

A hipótese explorada neste estudo é a utilização de rede neural artificial para realizar a tarefa de *peak finding* obtendo uma acurácia superior a de outras técnicas. Portanto, o objeto deste estudo é um agente inteligente simples, tal que sua função de agente, identificar a frequência cardíaca, será implementada por uma rede neural artificial baseada em perceptron multicamadas (MLP). A medida de desempenho é a acurácia da frequência cardíaca. Como a técnica de RNA utiliza informações sobre a forma do pico, é esperado uma eficiência superior a outros algoritmos existentes de *peak finding*.

Os dados foram obtidos da base de dados do MIT disponível em [8] que contém vários bancos de dados relacionados a eletrocardiogramas. A entrada foi discretizada para cada neurônio de entrada ter uma resposta binária e a saída representa se o ponto em questão é pico ou não.

O treinamento da rede foi executado utilizando dados de entrada contidos em [9]. Para o treinamento foi utilizado o ECG de apenas um paciente, e para a validação foi utilizado o ECG de dois pacientes diferentes do primeiro.

II. Peak Finding

No artigo [5] foi realizado um pré processamento nos dados com: análise de componentes principais (PCA); transformação discreta de cosseno (DCT) e a transformada discreta de Wavelet (DWT). Cada uma das três técnicas foi combinada com redes neurais de base radial (RBF) ou com rede SOFM para otimizar a performance da RNA ao identificar três padrões de onda, um normal e dois diagnósticos de arritmia. A topologia da RNA utilizada possui uma camada oculta de 15 neurônios e três neurônios de saída para classificar o batimento cardíaco em um dos três padrões: normal, fusão e contração prematura ventricular (PVC). Comparando com as técnicas de análise de discriminante linear e árvores hierárquicas, a RNA obteve performance

superior às demais. Os autores destacaram que a RNA pode ser melhorada com um ajuste na topologia da rede, regras de aprendizagem, número de iterações do treinamento e taxa de aprendizado. Os resultados obtidos da técnica de DCT ficaram próximos aos ótimos, e a combinação de MLP com DCT ou PCA é promissora, segundo os autores do artigo.

No artigo [2] o autor utilizou uma MLP para detectar picos em sinais de radar. Foi utilizado *backpropagation* para o treinamento da RNA. Os resultados do *peak finding* obtidos pela RNA foram comparados com duas outras técnicas comumente usadas para a finalidade: *threshold detector* e *OS-CFAR detector*. A RNA superou as outras técnicas com uma taxa de detecção superior especialmente com baixas taxas de alarme falso, mesmo variando a relação sinal-ruído (SNR).

III. Especificação do agente

A função do agente é identificar os batimentos cardíacos contidos nos sinais do ECG. O programa do agente recebe como entrada uma faixa de dados do ECG que vai se deslocando a cada iteração. Após passar os dados pela RNA MLP, o agente retorna se o ponto é batimento ou não. Quando retornar verdadeiro será armazenado o instante t_i para a obtenção da frequência cardíaca.

A medida de desempenho é a acurácia do resultado com o real. Os dados utilizados como entrada são da base de dados MIT-BIH [8] contendo, além dos dados, anotações corretas utilizadas para treinamento e medida de desempenho da rede.

O ambiente de atuação do agente único é parcialmente observável, pois o agente não considera informações sobre as condições físicas do paciente, tais como subindo uma escada, correndo, repouso, etc.

Se a saída fosse determinada considerando apenas o ponto atual, o ambiente seria determinístico, porém, o algoritmo não se baseia apenas naquele ponto, ele observa pontos anteriores e posteriores, e como existe uma probabilidade associada ao resultado, o ambiente é estocástico.

A frequência cardíaca não é uma constante. Ela está associada às condições física e emocional do paciente. O padrão pode sofrer algumas alterações ao longo do tempo, portanto, o ambiente é dinâmico.

Para o funcionamento do coração é produzida uma tensão que varia com o tempo de forma contínua. As informações de tensão obtidas pelos eletrodos são discretizados para serem armazenadas em vetores, caracterizando um ambiente discreto com os dados utilizados.

Como o agente terá que passar por uma etapa de aprendizagem do tipo *backpropagation*, ele é baseado em aprendizagem e o ambiente é desconhecido, isto significa que não existe uma fórmula matemática conhecida capaz de retornar o ponto do batimento.

IV. Topologia da rede

A rede neural artificial utilizada do tipo perceptron multicamadas foi implementada com seis camadas neuronais, sendo uma camada de entrada, quatro camadas ocultas e uma camada de saída.

A camada de entrada contém vinte e um neurônios. Cada neurônio possui uma entrada binária e cada grupo de três neurônios representa um valor de tensão do ECG.

A primeira camada oculta é composta por dezoito neurônios os quais suas saídas estão conectadas a segunda camada oculta com quinze neurônios. A terceira e a quarta camada oculta contém oito neurônios cada uma.

A última camada, ou camada de saída, possui um neurônio cuja saída binária representa se os valores de tensão recebidos na camada de entrada são de pico ou não.

A função de ativação utilizada foi a função degrau por ser a que conseguiu convergir comparada com a função sigmoide.

V. Dados de entrada

A base de dados do MIT-BIH [8] contém 30 minutos de gravação do ECG de 47 indivíduos. Após a conversão para um arquivo texto, a primeira coluna é o instante de tempo em medido pelo eletrodo, a segunda coluna representa o valor da diferença de potencial obtida entre o eletrodo e o terra. Todas as gravações contém anotações e informações como o instante em que houve batimento cardíaco.

Os dados de entrada para o treinamento da RNA foram obtidos em [9], que é um programa auxiliar para visualizar as amostras e os instantes de batimento cardíaco.

Para o bom funcionamento da rede, os dados de entrada foram discretizados utilizando a seguinte função:

$$F(x) : \begin{array}{ll} 000, & \text{para } x < 0,0; \\ 001, & \text{para } 0,0 \geq x < 0,2; \\ 010, & \text{para } 0,2 \geq x < 0,5; \\ 011, & \text{para } 0,5 \geq x < 0,7; \\ 100, & \text{para } 0,7 \geq x < 0,9; \\ 101, & \text{para } 0,9 \geq x < 1,0; \\ 110, & \text{para } 1,0 \geq x < 1,2; \\ 111, & \text{para } x \geq 1,2; \end{array}$$

Em que x é a diferença de potencial contida no arquivo texto.

Com essa discretização, cada valor de tensão será representado por três bits. Portanto, para a rede neural ler uma faixa de sete valores de tensão ela deve ter três neurônios para

cada valor, totalizando vinte e um neurônios na camada de entrada.

VI. Treinamento da rede

O instante que caracterizou um batimento cardíaco foi obtido em [9] e foi submetido a um programa que busca este tempo no arquivo texto. Quando pico é encontrado, o programa gera três linhas de treinamento: a primeira com valores de tensão anteriores ao pico e com o valor desejado de saída zero; a segunda com os valores de tensão centralizados no pico, ou seja, o valor de pico entra no neurônio do meio, no caso, o quarto neurônio e a saída desejada com o valor um; a terceira linha de treinamento é gerada com valores posteriores ao pico, com o valor desejado para a saída igual a zero.

Este procedimento foi realizado para vários valores de pico, totalizando trezentas linhas de treinamento, que serviram de entrada para a etapa de *backpropagation* junto com o arquivo texto contendo todos os valores de tensão. A rede conseguiu aprender as regras geradas e retornou os valores dos pesos calibrados.

VII. Execução do programa

Após o treinamento, o programa foi executado recebendo como entrada arquivos texto de tensões de indivíduos diferentes do utilizado para o treinamento.

A saída obtida, se é batimento ou não, foi sintetizada e transformada em frequência cardíaca para cada minuto dos dados de entrada.

Os dados obtidos para o terceiro indivíduo estão na tabela 7.1, que contém o número real de batimentos para cada minuto e o número de batimentos que o programa conseguiu identificar.

Minuto	Batimentos real	Batimentos medidos	Diferença
1º	70	70	0
2º	70	70	0
3º	72	74	2
4º	70	70	0
5º	73	75	2
6º	70	71	1
7º	69	69	0

8º	69	70	1
9º	70	71	1

Tabela 7.1: quantidade de batimentos medidos e realmente ocorridos nos nove primeiros minutos do terceiro indivíduo.

Além do terceiro indivíduo, a rede foi submetida aos dados do quinto indivíduo que obteve resultados semelhantes aos do terceiro.

VIII. Conclusões

Como a rede neural artificial utiliza a forma da onda QRS para encontrar o batimento, a mesma não teve muita dificuldade de treinamento. Os resultados, em vários minutos, tiveram uma acurácia de cem por cento. Em alguns pontos, onde existiam mais ruídos, os resultados tiveram uma acurácia por volta de noventa e cinco por cento.

Estudos posteriores podem trabalhar melhorando estes resultados submetendo a rede a uma etapa de aprendizado mais diversificada utilizando dados de outros pacientes na etapa de geração das linhas de treinamento.

Uma alteração na topologia também pode ser discutida em estudos posteriores, aumentando a quantidade de neurônios na camada de entrada e reduzindo a quantidade de camadas ocultas.

REFERÊNCIAS

- [1] D. S. Melo. Reconhecimento de Padrões Sobre Sinais de ECG utilizando Técnicas Sintáticas, TCC, Departamento de Informática e Estatística, Universidade Federal de Santa Catarina, 2013
- [2] S. Wunsch, J. Fink, F. K. Jondral. "Improved Detection by Peak Shape Recognition Using Artificial Neural Networks." IEEE 82nd Vehicular Technology Conference, Boston, 2015.
- [3] Richards, Mark A. Fundamentals of radar signal processing. Tata McGraw-Hill Education, 2005.
- [4] Rohling, Hermann. "Radar CFAR thresholding in clutter and multiple target situations." Aerospace and Electronic Systems, IEEE Transactions on 4 (1983): 608-621.
- [5] R. Ghongade; A. Ratnaparkhi; D. Joshi. "Artificial Neural Network based electrocardiogram pattern recognition." IEEE Third International Conference on Computational Intelligence and Information Technology (CIIT 2013), 2013.
- [6] Rajesh Ghongade, Dr. A.A. Ghatol, "A Brief Performance Evaluation of ECG Feature Extraction Techniques for Artificial Neural Network Based Classification", published in IEEE 2007.
- [7] Russel, S., Norvig, P. (1995). "Artificial Intelligence, a Modern Approach", New Jersey: Prentice Hall International.
- [8] <http://physionet.org/physiobank/database/mitdb/> Acessos em: outubro a dezembro de 2017.
- [9] <https://www.physionet.org/cgi-bin/atm/ATM> Acessos em: outubro a dezembro de 2017.